

否则。第一种情况仅在稀疏性最严重时发生：即梯度在所有时间步除当前时间步外均为零。对于稀疏性较低的情况，有效步长会更小。当 $(1 - \beta_1) = \sqrt{1 - \beta}$ 时，我们有 $|\hat{m}_t / \sqrt{\hat{v}_t}| < 1$ ，因此 $|\Delta_t| \lesssim \alpha$ 。在更普遍的情况下，参数空间中我们探索的步骤的有效幅度大致由步长 $\sqrt{\mathbb{E}[g_t^2]}$ 设置，i.e., $|\Delta_t| \lesssim \alpha$ 界定。这可以理解为在当前参数值周围建立一个信任区域，超出该区域当前梯度估计无法提供足够信息。这通常使得提前知道 α 的正确尺度相对容易。例如，对于许多机器学习模型，我们通常提前知道好的最优解以高概率位于参数空间中的某个设定区域内；例如，对参数具有先验分布并不罕见。由于 α 设定了参数空间中步骤幅度的上限，我们通常可以推断出 α 的正确数量级，使得从 θ_0 开始在一定迭代次数内能够到达最优解。稍微滥用术语，我们将比率 $\hat{m}_t / \sqrt{\hat{v}_t}$ 称为信噪比（ SNR ）。信噪比较小时，有效步长 Δ_t 将更接近零。这是一个理想的特性，因为较小的信噪比意味着关于 $\hat{m}_t$ 的方向是否与真实梯度方向一致存在更大的不确定性。例如，信噪比值通常在接近最优解时趋向于 0，导致参数空间中的有效步长更小：一种自动退火形式。有效步长 Δ_t 对梯度的尺度也不变；将梯度 g_t 缩放因子 c 将缩放 $\hat{m}_t$ 因子 c 和 $\hat{v}_t$ 因子 c^2 ，它们相互抵消： $(c \cdot \hat{m}_t) / \sqrt{c^2 \cdot \hat{v}_t}$

$$\frac{c \cdot \hat{m}_t}{\sqrt{c^2 \cdot \hat{v}_t}} = \hat{m}_t / \sqrt{\hat{v}_t}.$$

3 初始化偏差校正

如第 2 节所述，Adam 利用了初始化偏差校正项。本文在此推导二阶矩估计的校正项；一阶矩估计的推导完全类似。设 g 为随机目标 f 的梯度，我们希望使用平方梯度的指数移动平均来估计其二阶原点矩（未中心化的方差），衰减率为 β_2 。设 $g_1, \dots, g_T$ 为后续时间步的梯度，每个梯度均从底层梯度分布 $g_t \sim p(g_t)$ 中抽取。将指数移动平均初始化为 $v_0 = 0$ （零向量）。首先注意到，在

时间步 t 处，指数移动平均 $v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ （其中 g_t^2 表示逐元素平方 $g_t \odot g_t$ ）的更新可以表示为所有先前时间步梯度的函数：

$$v_t = (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} \cdot g_i^2 \quad (1)$$

我们希望了解 $\mathbb{E}[v_t]$ ，即时间步 t 处指数移动平均的期望值，与真实二阶矩 $\mathbb{E}[g_t^2]$ 之间的关系，以便校正两者之间的偏差。对式 (1) 左右两边取期望：

$$\mathbb{E}[v_t] = \mathbb{E} \left[(1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} \cdot g_i^2 \right] \quad (2)$$

$$= \mathbb{E}[g_t^2] \cdot (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} + \zeta \quad (3)$$

$$= \mathbb{E}[g_t^2] \cdot (1 - \beta_2^t) + \zeta \quad (4)$$

其中，若真实二阶矩 $\mathbb{E}[g_t^2]$ 是平稳的，则 $\zeta = 0$ ；否则，由于指数衰减率 β_1 可以（且应当）选择为使指数移动平均对过于久远的梯度赋予较小权重，因此 ζ 可以保持较小。剩余项 $(1 - \beta_2^t)$ 是由将滑动平均初始化为零引起的。因此，在算法 1 中，本文除以该项以校正初始化偏差。在梯度稀疏的情况下，为了可靠地估计二阶矩，需要通过选择较小的 β_2 值来对多个梯度进行平均；然而，正是在这种 β_2 较小的情况下，缺乏初始化偏差校正会导致初始步长过大。

来自一阶信息。函数求和优化器 (Sum-of-Functions Optimizer, SFO) (Sohl-Dickstein 等人, 2014) 是一种基于小批量的拟牛顿方法, 但与 Adam 不同, 其内存需求与数据集的小批量划分数量成线性关系, 这在诸如 GPU 等内存受限系统上通常不可行。与自然梯度下降 (Natural Gradient Descent, NGD) (Amari, 1998) 类似, Adam 采用了一个适应数据几何结构的预处理器, 因为 $\hat{v}_t$ 是对费舍尔信息矩阵 (Fisher Information Matrix) 对角线的近似 (Pascanu 和 Bengio, 2013); 然而, Adam 的预处理器 (与 AdaGrad 类似) 在自适应方面比标准 NGD 更为保守, 它使用对角线费舍尔信息矩阵近似的逆矩阵的平方根进行预处理。

RMSProp: 与 Adam 密切相关的一种优化方法是 **RMSProp** (Tieleman 和 Hinton, 2012)。有时会使用带有动量的版本 (Graves, 2013)。带有动量的 **RMSProp** 与 Adam 之间存在几个重要区别: 带有动量的 **RMSProp** 使用缩放后梯度的动量来生成参数更新, 而 Adam 的更新则直接使用梯度一阶矩和二阶矩的滑动平均进行估计。**RMSProp** 还缺少偏差校正项; 这在 β_2 接近 1 时 (稀疏梯度情况下需要) 影响最大, 因为在这种情况下不校正偏差会导致非常大的步长, 并经常导致发散, 我们也在第 6.4 节中通过实验证明了这一点。

AdaGrad: 一种适用于稀疏梯度的算法是 **AdaGrad** (Duchi 等人, 2011)。其基本版本按任意方式更新参数选择 β_2 从下方无限接近 1, 则 $\sqrt{\sum_{i=1}^t g_i^2}$ 。AdaGrad 对应于 Adam 的一个版本, 其中 $\beta_1 = 0$, $(1 - \beta_2)$ 为无穷小, 并且将 α 替换为退火版本 $\alpha_t = \alpha \cdot t^{-1/2}$, 即 $\theta_t - \alpha \cdot t^{-1/2} \cdot \hat{m}_t / \sqrt{\lim_{\beta_2 \rightarrow 1} \hat{v}_t} = \theta_t - \alpha \cdot t^{-1/2} \cdot g_t / \sqrt{t^{-1} \cdot \sum_{i=1}^t g_i^2}$ 。注意, 当去除偏差校正项时, Adam 与 AdaGrad 之间的这种直接对应关系不再成立: 如果没有偏差校正, 就像在 RMSProp 中一样, β_2 无限接近 1 会导致无限大的偏差, 以及无限大的参数更新。

6 实验

为实证评估所提方法, 本文考察了多种流行的机器学习模型, 包括逻辑回归、多层全连接神经网络和深度卷积神经网络。通过使用大规模模型与数据集, 本文证明 Adam 能够高效地解决实用的深度学习问题。在比较不同优化算法时, 本文采用相同的参数初始化方式。学习率、动量等超参数在密集网络上进行搜索, 并报告最佳超参数设置下的结果。

6.1 实验: 逻辑回归

本文在 MNIST 数据集上使用 L2 正则化的多类逻辑回归对所提方法进行评估。逻辑回归具有研究充分的凸目标函数, 适合用于比较不同优化器, 而无需担心局部极小值问题。逻辑回归实验中的步长 α 通过 $1/\sqrt{t}$ 衰减进行调整, 即 $\alpha_t = \frac{\alpha}{\sqrt{t}}$, 这与第 4 节的理论预测相符。逻辑回归直接在 784 维图像向量上进行类别标签分类。本文在批量大小为 128 的设置下, 将 Adam 与带 Nesterov 动量的加速 SGD 以及 Adagrad 进行比较。根据图 1, 本文发现 Adam 的收敛性与带动量的 SGD 相似, 且两者均比 Adagrad 收敛更快。正如 (Duchi 等人, 2011) 所讨论的, Adagrad 的主要理论成果之一是其能够高效处理稀疏特征和梯度, 而 SGD 在学习稀有特征方面表现较差。步长采用 $1/\sqrt{t}$ 衰减的 Adam 在理论上应与 Adagrad 的性能相当。本文使用 (Maas 等人, 2011) 的 IMDB 电影评论数据集来检验稀疏特征问题。本文将 IMDB 电影评论预处理为词袋 (BoW) 特征向量, 包含前 10,000 个最频繁出现的单词。每条评论的 10,000 维词袋特征向量高度稀疏。如 (Wang 和 Manning, 2013) 所建议, 在训练过程中可对词袋特征施加 50% 的随机失活噪声。

Algorithm 2: *AdaMax*, a variant of Adam based on the infinity norm. See section 7.1 for details. Good default settings for the tested machine learning problems are $\alpha = 0.002$, $\beta_1 = 0.9$ and $\beta_2 = 0.999$. With β_1^t we denote β_1 to the power t . Here, $(\alpha/(1 - \beta_1^t))$ is the learning rate with the bias-correction term for the first moment. All operations on vectors are element-wise.

Require: α : Stepsize

Require: $\beta_1, \beta_2 \in [0, 1]$: Exponential decay rates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$u_0 \leftarrow 0$ (Initialize the exponentially weighted infinity norm)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$u_t \leftarrow \max(\beta_2 \cdot u_{t-1}, |g_t|)$ (Update the exponentially weighted infinity norm)

$\theta_t \leftarrow \theta_{t-1} - (\alpha/(1 - \beta_1^t)) \cdot m_t/u_t$ (Update parameters)

end while

return θ_t (Resulting parameters)

注意，这里的衰减项等价地参数化为 β_2^p 而不是 β_2 。现在令 $p \rightarrow \infty$ ，
 $u_t = \lim_{p \rightarrow \infty} (v_t)^{1/p}$ ，~~并定义~~

$$u_t = \lim_{p \rightarrow \infty} (v_t)^{1/p} = \lim_{p \rightarrow \infty} \left((1 - \beta_2^p) \sum_{i=1}^t \beta_2^{p(t-i)} \cdot |g_i|^p \right)^{1/p} \quad (8)$$

$$= \lim_{p \rightarrow \infty} (1 - \beta_2^p)^{1/p} \left(\sum_{i=1}^t \beta_2^{p(t-i)} \cdot |g_i|^p \right)^{1/p} \quad (9)$$

$$= \lim_{p \rightarrow \infty} \left(\sum_{i=1}^t \left(\beta_2^{(t-i)} \cdot |g_i| \right)^p \right)^{1/p} \quad (10)$$

$$= \max(\beta_2^{t-1}|g_1|, \beta_2^{t-2}|g_2|, \dots, \beta_2|g_{t-1}|, |g_t|) \quad (11)$$

这对应于极其简单的递归公式：

$$u_t = \max(\beta_2 \cdot u_{t-1}, |g_t|) \quad (12)$$

初始值为 $u_0 = 0$ 。注意，方便的是，在这种情况下我们不需要校正初始化偏差。还要注意，使用 AdaMax 时参数更新的幅度比 Adam 有更简单的界限，即： $|\Delta \theta_t| \leq \alpha$ 。

7.2 时间平均

由于随机近似导致最终迭代值存在噪声，通常通过平均来获得更好的泛化性能。此前，Moulines 与

Bach (2011) 已证明 Polyak-Ruppert 平均 (Polyak 与 Juditsky, 1992;

Ruppert, 1988) 能改善标准随机梯度下降的收敛性，其中 $\theta_t = \frac{1}{t} \sum_{k=1}^t \theta_k$ 。或者，可对参数使用指数移动平均，赋予较新的参数值更高的权重。这可通过在算法 1 和算法 2 的内循环中添加一行来简单实现：

$\theta_t \leftarrow \beta_2 \cdot \theta_{t-1} + (1 - \beta_2) \theta_t$ ，其中 $\theta_0 = 0$ 。初始化偏差同样可通过估计量 $\hat{\theta}_t = \bar{\theta}_t / (1 - \beta_2^t)$ 进行校正。

8 CONCLUSION

本文提出了一种简单且计算高效的算法，用于基于梯度的随机目标函数优化。该方法针对机器学习问题，