

解码器通常被训练为在给定上下文向量 c 和所有先前预测的词 $\{y_1, \dots, y_{t-1}\}$ 的条件下预测下一个词 y_t 。换句话说，解码器通过将联合概率分解为有序条件概率来定义翻译 $\mathbf{y}$ 上的概率：

$$p(\mathbf{y}) = \prod_{t=1}^T p(y_t | \{y_1, \dots, y_{t-1}\}, c), \quad (2)$$

$(y_1, \dots, y_{T_y})$ 其中 $\mathbf{y} =$ 。使用 RNN 时，每个条件概率被建模为

$$p(y_t | \{y_1, \dots, y_{t-1}\}, c) = g(y_{t-1}, s_t, c), \quad (3)$$

其中 g 是一个非线性、可能多层的函数，输出 y_t 的概率， s_t 是 RNN 的隐藏状态。应当注意，也可以使用其他架构，例如 RNN 与反卷积神经网络的混合架构（Kalchbrenner 和 Blunsom, 2013）。

3 学习对齐与翻译

在本节中，我们提出一种新颖的神经机器翻译架构。该新架构由一个作为编码器的双向 RNN（第 3.2 节）和一个在解码翻译时模拟搜索源句子的解码器（第 3.1 节）组成。

3.1 解码器：总体描述

在新模型架构中，我们将式 (2) 中的每个条件概率定义为：

$$p(y_i | y_1, \dots, y_{i-1}, \mathbf{x}) = g(y_{i-1}, s_i, c_i), \quad (4)$$

其中 s_i 是时间 i 的循环神经网络 (RNN) 隐藏状态，由下式计算：

$$s_i = f(s_{i-1}, y_{i-1}, c_i).$$

需要指出的是，与现有的编码器-解码器方法（见式 (2)）不同，这里的概率以每个目标词 y_i 对应的不同上下文向量 c_i 为条件。

上下文向量 c_i 依赖于编码器将输入句子映射得到的一组标注 $(h_1, \dots, h_{T_x})$ 。每个标注 h_i 包含整个输入序列的信息，并重点关注输入序列中第 i 个词周围的部分。我们将在下一节详细解释标注的计算方式。

然后，上下文向量 c_i 计算为这些标注的加权和：
 h_i :

$$c_i = \sum_{j=1}^{T_x} \alpha_{ij} h_j. \quad (5)$$

每个标注 h_j 的权重 α_{ij} 由下式计算：

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})}, \quad (6)$$

其中

$$e_{ij} = a(s_{i-1}, h_j)$$

是对齐模型，用于评估位置 j 附近的输入与位置 i 处的输出之间的匹配程度。该评分基于循环神经网络 (RNN) 隐藏状态 s_{i-1} （在输出 y_i 之前，式 (4)）以及输入句子的第 j 个标注 h_j 。

我们将对齐模型 a 参数化为一个前馈神经网络，该网络与所提出系统的所有其他组件联合训练。注意，与传统的机器翻译不同，




图 1：所提出模型的图示，该模型在给定源句子 $(x_1, x_2, \dots, x_T)$ 的条件下尝试生成第 t 个目标词 y_t 。