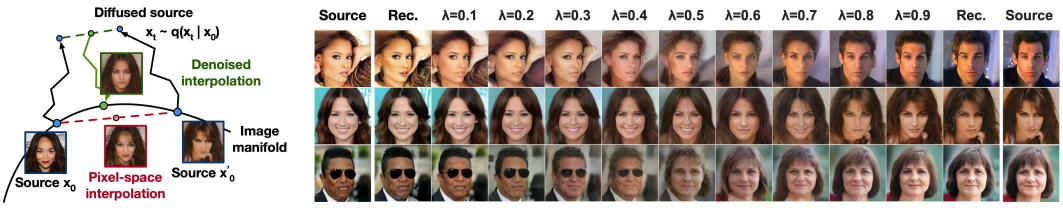

图 8：使用 500 个扩散时间步对 CelebA-HQ 256x256 图像进行插值。

D_{KL} $\mathbf{x}_{t-1}|\mathbf{x}_t) \parallel p_\theta(\mathbf{x}_{t-1}\ \mathbf{x}_t))$ trains p_θ 复制坐标

ct th coordinate give

T $t+1, \ldots, T$

保持不变表达的给定分布。在这些选择下，预测第 $q(\mathbf{x}_T \mid \mathbf{x}_0)$ 个坐标，因此，用这种特定扩散训练 p_θ 就是在训练一个自回归模型。

因此，我们可以将高斯扩散模型（2）解释为一种具有广义位序的自回归模型，这种位序无法通过重新排列数据坐标来表达。先前的工作表明，这种重排会引入影响样本质量的归纳偏置 [38]，因此我们推测高斯扩散具有类似的作用，而且可能效果更显著，因为与掩蔽噪声相比，高斯噪声添加到图像上可能更自然。此外，高斯扩散的长度并不限于等于数据维度；例如，在我们的实验中，我们使用的 $T = 1000$, 小于 $32 \times 32 \times 3$ 或 $256 \times 256 \times 3$ 图像的维度。高斯扩散可以缩短以实现快速采样，也可以延长以提高模型表达能力。

4.4 插值

我们可以使用 q 作为随机编码器，在潜空间中插值源图像 $\mathbf{x}_0, \mathbf{x}'_0 \sim q(\mathbf{x}_0)$ ， $\mathbf{x}_t, \mathbf{x}'_t \sim q(\mathbf{x}_t|\mathbf{x}_0)$ ，然后通过逆向过程将线性插值的潜变量 $\bar{\mathbf{x}}_t = (1-\lambda)\mathbf{x}_0 + \lambda\mathbf{x}'$ 0 解码回图像空间， $\bar{\mathbf{x}}_0 \sim p(\mathbf{x}_0|\bar{\mathbf{x}}_t)$ 。实际上，我们使用逆向过程来消除对源图像的损坏版本进行线性插值所产生的伪影，如图 8（左）所示。我们固定了不同 λ so $\mathbf{x}_t$ 值下的噪声，并且 $\mathbf{x}'_t$ 保持不变。图 8（右）展示了原始 CelebA-HQ 256×256 图像（ $t = 500$ ）的插值和重建。逆向过程产生了高质量的重建结果，以及合理的插值结果，这些插值平滑地改变了姿态、肤色、发型、表情和背景等属性，但不包括眼镜。较大的 t 会产生更粗糙且更多样化的插值，并在 $t = 1000$ 处产生新颖的样本（附录图 9）。

5 相关工作

尽管扩散模型可能类似于流模型 [9, 46, 10, 32, 5, 16, 23] 和变分自编码器 [33, 47, 37]，但扩散模型的设计使得 q 没有参数，且顶层潜变量 $\mathbf{x}_T$ 与数据 $\mathbf{x}_0$ 之间的互信息几乎为零。本文提出的 ϵ 预测反向过程参数化方法，在多个噪声水平上建立了扩散模型与去噪分数匹配之间的联系，并利用退火朗之万动力学进行采样 [55, 56]。然而，扩散模型允许直接进行对数似然评估，且训练过程通过变分推断显式地训练朗之万动力学采样器（详见附录 C）。这种联系还反过来表明，某种加权形式的去噪分数匹配等价于训练朗之万型采样器的变分推断。其他学习马尔可夫链转移算子的方法包括注入训练 [2]、变分回退 [15]、生成随机网络 [1] 等 [50, 54, 36, 42, 35, 65]。

基于分数匹配与基于能量的建模之间的已知联系，本文的工作可能对近期基于能量的模型 [67 – 69, 12, 70, 13, 11, 41, 17, 8] 研究具有启示意义。本文的率失真曲线是在一次变分界评估中随时间计算得到的，这类似于在退火重要性采样 [24] 的一次运行中，通过改变失真惩罚来计算率失真曲线。本文的渐进解码思想可以在卷积 DRAW 及相关模型 [18, 40] 中看到，也可能为自回归模型 [38, 64] 的子尺度排序或采样策略带来更通用的设计。