

表示 $z = \mathcal{E}(x)$ ，解码器 $\mathcal{D}$ 从潜在表示重建图像，得到 $\tilde{x} = \mathcal{D}(z) = \mathcal{D}(\mathcal{E}(x))$ ，其中。重要的是，编码器以因子 $z \in \mathbb{R}^{h \times w \times c}$ $f = H/h = W/w$ 对图像进行下采样，我们研究了不同的下采样因子 $f = 2^m$ ，其中 $m \in \mathbb{N}$ 。

为了避免任意高方差的潜空间，我们尝试了两种不同的正则化方法。第一种变体，KL 正则化，对学习到的潜变量施加一个轻微的标准正态 KL 惩罚，类似于变分自编码器 (VAE) [46, 69]；而 VQ 正则化则在解码器内部使用向量量化层 [96]。该模型可以解释为 VQGAN [23]，但量化层被解码器吸收。由于我们后续的扩散模型 (DM) 设计用于处理学习到的潜空间的二维结构 $z = \mathcal{E}(x)$ ，我们可以使用相对温和的压缩率并实现非常好的重建效果。这与之前的工作 [23, 66] 形成对比，之前的工作依赖于学习空间的任意一维排序 z 来自回归地建模其分布，从而忽略了 z 的大部分固有结构。因此，我们的压缩模型更好地保留了 x 的细节（见表 8）。完整的目标函数和训练细节可在补充材料中找到。

3.2. 潜空间扩散模型

扩散模型 [82] 是概率模型，旨在通过逐步去噪一个正态分布变量来学习数据分布 $p(x)$ ，这相当于学习一个固定长度马尔可夫链 T 的反向过程。对于图像合成，最成功的模型 [15, 30, 72] 依赖于 $p(x)$ 上变分下界的重新加权变体，这反映了去噪得分匹配 [85]。这些模型可以解释为等权重的去噪自编码器序列 $\epsilon_\theta(x_t, t); t = 1 \dots T$ ，它们被训练来预测其输入的降噪变体 x_t ，其中 x_t 是输入 x 的噪声版本。相应的目标函数可以简化为（见 B 节）

$$L_{DM} = \mathbb{E}_{x, \epsilon \sim \mathcal{N}(0,1), t} [\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2], \quad (1)$$

其中 t 从 $\{1, \dots, T\}$ 中均匀采样。潜表示的生成建模借助我们训练好的感知压缩模型，包括 $\mathcal{E}$ 和 $\mathcal{D}$ ，我们现在可以访问一个高效、低维的潜空间，其中高频、不可感知的细节被抽象掉。

与高维像素空间相比，这个空间更适合基于似然的生成模型，因为它们现在可以 (i) 专注于数据中重要的语义部分，并且 (ii) 在更低维、计算效率更高的空间中训练。与之前依赖自回归、基于注意力的变换器模型在高度压缩的离散潜空间 [23, 66, 103] 中的工作不同，我们可以利用我们的模型提供的图像特定的归纳偏置。这




图 3. 我们通过拼接或更通用的交叉注意力机制来条件化潜在扩散模型。参见第 3.3 节，包括主要从二维卷积层构建底层 UNet 的能力，并进一步利用重新加权的界将目标聚焦于感知上最相关的位，该界现在表示为

$$L_{LDM} := \mathbb{E}_{\mathcal{E}(x), \epsilon \sim \mathcal{N}(0,1), t} [\|\epsilon - \epsilon_\theta(z_t, t)\|_2^2]. \quad (2)$$

我们模型的神经骨干 $\epsilon_\theta(\cdot, t)$ 实现为时间条件 UNet [71]。由于前向过程是固定的， z_t 可以在训练期间从 $\mathcal{E}$ 高效获得，并且来自 $p(z)$ 的样本可以通过一次通过 $\mathcal{D}$ 解码到图像空间

3.3. 条件机制

与其他类型的生成模型 [56, 83] 类似，扩散模型原则上能够建模形式为 $p(z|y)$ 的条件分布。这可以通过条件去噪自编码器来实现 $\epsilon_\theta(z_t, t, y)$ 并为通过输入 y （如文本 [68]、语义图 [33, 61] 或其他图像到图像转换任务 [34]）控制综合过程铺平了道路。

然而，在图像综合的背景下，将扩散模型的生成能力与除类标签 [15] 或输入图像的模糊变体 [72] 之外的其他条件相结合，迄今为止是一个研究不足的领域。我们通过在其底层 UNet 骨干上增加交叉注意力机制 [97]，将扩散模型转变为更灵活的条件图像生成器，该机制对于学习各种输入模态的基于注意力的模型是有效的 [35, 36]。为了预处理来自各种模态（如语言提示）的 y ，我们引入了一个领域特定的编码器 τ_θ ，它将 y 投影到中间表示

$\tau_\theta(y) \in \mathbb{R}^{M \times d_\tau}$ ，然后通过实现以下内容的交叉注意力层映射到 UNet 的中间层

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \cdot V, \text{ with}$$

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t), K = W_K^{(i)} \cdot \tau_\theta(y), V = W_V^{(i)} \cdot \tau_\theta(y).$$

Here, $\varphi_i(z_t) \in \mathbb{R}^{N \times d_\epsilon^i}$ denotes a (flattened) intermediate representation of the UNet implementing ϵ_θ and $W_V^{(i)} \in$