

否则。第一种情况仅在稀疏性最严重时发生：即梯度在所有时间步均为零，仅当前时间步除外。对于稀疏性较低的情况，有效步长会更小。当 $(1 - \beta_1) = \sqrt{1 - \beta}$ 时，我们有 $|\hat{m}_t/\sqrt{\hat{v}_t}| < 1$ ，因此 $|\Delta_t| < \alpha$ 。在更常见的场景中，我们将有 $\hat{m}_t/\sqrt{\hat{v}_t} \approx \pm 1$ ，因为 $|\mathbb{E}[g]|/\sqrt{\mathbb{E}[g^2]} \leq 1$ 。每个时间步在参数空间中采取的步骤的有效幅度大致以步长设置为界 α ，i.e., $|\Delta_t| \lesssim \alpha$ 。这可以理解为在当前参数值周围建立一个信任区域，超出该区域，当前梯度估计无法提供足够的信息。这通常使得事先相对容易知道 α 的正确尺度。例如，对于许多机器学习模型，我们通常事先知道好的最优解以高概率位于参数空间中的某个设定区域内；例如，对参数有一个先验分布并不罕见。由于 α 设定了参数空间中步骤幅度的（上界），我们通常可以推断出 α 的正确数量级，使得最优解可以在一定迭代次数内从 θ_0 处到达。稍微滥用术语，我们将比率 $\hat{m}_t/\sqrt{\hat{v}_t}$ 称为信噪比（SNR）。信噪比越小，有效步长 Δ_t 越接近零。这是一个理想的特性，因为较小的信噪比意味着关于 $\hat{m}_t$ 的方向是否对应于真实梯度方向的不确定性更大。例如，信噪比值通常在接近最优解时趋向于 0，导致参数空间中的有效步长更小：一种自动退火的形式。有效步长 Δ_t 对梯度的尺度也是不变的；将梯度 g 缩放因子 c 会以因子 c 缩放 $\hat{m}_t$ ，并以因子 c^2 缩放 $\hat{v}_t$ ，两者相互抵消：

$$(c \cdot \hat{m}_t)/(\sqrt{c^2 \cdot \hat{v}_t}) = \hat{m}_t/\sqrt{\hat{v}_t}.$$

3 初始化偏差校正

如第 2 节所述，Adam 利用了初始化偏差校正项。本文在此推导二阶矩估计的该项；一阶矩估计的推导完全类似。设 g 为随机目标 f 的梯度，我们希望使用平方梯度的指数移动平均来估计其二阶原点矩（未中心化方差），衰减率为 β_2 。设 $g_1, \dots, g_t$ 为后续时间步的梯度，每个梯度均从底层梯度分布 $g_t \sim p(g_t)$ 中抽取。将指数移动平均初始化为 $v_0 = 0$ （零向量）。首先注意，在时间步

t 处指数移动平均 $v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ （其中 g_t^2 表示逐元素平方 $g_t \odot g_t$ ）的更新可以表示为所有先前时间步梯度的函数：

$$v_t = (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} \cdot g_i^2 \quad (1)$$

我们希望了解 $\mathbb{E}[v_t]$ ，即时间步 t 处指数移动平均的期望值，与真实二阶矩 $\mathbb{E}[g_t^2]$ 之间的关系，以便校正两者之间的偏差。对等式 (1) 左右两边取期望：

$$\mathbb{E}[v_t] = \mathbb{E} \left[(1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} \cdot g_i^2 \right] \quad (2)$$

$$= \mathbb{E}[g_t^2] \cdot (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} + \zeta \quad (3)$$

$$= \mathbb{E}[g_t^2] \cdot (1 - \beta_2^t) + \zeta \quad (4)$$

其中，若真实二阶矩 $\mathbb{E}[g_t^2]$ 是平稳的，则 $\zeta = 0$ ；否则，由于指数衰减率 β_1 可以（且应当）选择为使指数移动平均对过于久远的梯度赋予较小权重，因此 ζ 可以保持较小。剩余项 $(1 - \beta_2^t)$ 是由将滑动平均初始化为零引起的。因此，在算法 1 中，本文除以该项以校正初始化偏差。在梯度稀疏的情况下，为了可靠地估计二阶矩，需要通过选择较小的 β_2 值来对多个梯度进行平均；然而，正是在这种 β_2 较小的情况下，缺乏初始化偏差校正会导致初始步长过大。

Algorithm 2: *AdaMax*, a variant of Adam based on the infinity norm. See section 7.1 for details. Good default settings for the tested machine learning problems are $\alpha = 0.002$, $\beta_1 = 0.9$ and $\beta_2 = 0.999$. With β_1^t we denote β_1 to the power t . Here, $(\alpha/(1 - \beta_1^t))$ is the learning rate with the bias-correction term for the first moment. All operations on vectors are element-wise.

Require: α : Stepsize

Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$u_0 \leftarrow 0$ (Initialize the exponentially weighted infinity norm)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$u_t \leftarrow \max(\beta_2 \cdot u_{t-1}, |g_t|)$ (Update the exponentially weighted infinity norm)

$\theta_t \leftarrow \theta_{t-1} - (\alpha/(1 - \beta_1^t)) \cdot m_t/u_t$ (Update parameters)

end while

return θ_t (Resulting parameters)

注意，这里的衰减项等价地参数化为 β_2^p ，而不是 β_2 。现在令 $p \rightarrow \infty$ ，并定义

$u_t = \lim_{p \rightarrow \infty} (v_t)^{1/p}$, then:

$$u_t = \lim_{p \rightarrow \infty} (v_t)^{1/p} = \lim_{p \rightarrow \infty} \left((1 - \beta_2^p) \sum_{i=1}^t \beta_2^{p(t-i)} \cdot |g_i|^p \right)^{1/p} \quad (8)$$

$$= \lim_{p \rightarrow \infty} (1 - \beta_2^p)^{1/p} \left(\sum_{i=1}^t \beta_2^{p(t-i)} \cdot |g_i|^p \right)^{1/p} \quad (9)$$

$$= \lim_{p \rightarrow \infty} \left(\sum_{i=1}^t \left(\beta_2^{(t-i)} \cdot |g_i| \right)^p \right)^{1/p} \quad (10)$$

$$= \max(\beta_2^{t-1}|g_1|, \beta_2^{t-2}|g_2|, \dots, \beta_2|g_{t-1}|, |g_t|) \quad (11)$$

这对应于一个非常简单的递归公式：

$$u_t = \max(\beta_2 \cdot u_{t-1}, |g_t|) \quad (12)$$

初始值为 $u_0 = 0$ 。注意，很方便的是，在这种情况下我们不需要对初始化偏差进行校正。还要注意，与 Adam 相比，AdaMax 的参数更新幅度有一个更简单的界限，即： $|\Delta_t| \leq \alpha$ 。

7.2 时间平均

由于随机近似导致最终迭代存在噪声，通常通过平均来获得更好的泛化性能。此前在 Moulines & Bach (2011) 中，Polyak-Ruppert 平均 (Polyak & Juditsky, 1992; Ruppert, 1988) 已被证明能改善标准随机梯度下降的收敛性，其中 $\theta_t = \frac{1}{t} \sum_{k=1}^t \theta_k$ 。或者，可以对参数使用指数移动平均，赋予较新的参数值更高的权重。这可以通过在算法 1 和 2 的内循环中添加一行来简单实现：
 $\theta_t \leftarrow \beta_2 \cdot \theta_{t-1} + (1 - \beta_2) \theta_t$ ，其中 $\theta_0 = 0$ 。初始化偏差同样可以通过估计量 $\hat{\theta}_t = \bar{\theta}_t / (1 - \beta_2^t)$ 来校正。

8 CONCLUSION

本文提出了一种简单且计算高效的算法，用于基于梯度的随机目标函数优化。该方法主要面向机器学习问题，

10 附录

10.1 收敛性证明

定义 10.1. 函数 $f: R^d \rightarrow R$ 是凸的, 如果对于所有 $x, y \in R^d$, 对于所有 $\lambda \in [0, 1]$, $\lambda f(x) + (1 - \lambda)f(y) \geq f(\lambda x + (1 - \lambda)y)$

此外, 注意到凸函数可以在其切点处被一个超平面从下方界定。

引理 10.2. 如果函数 $f: R^d \rightarrow R$ 是凸的, 那么对于所有 $x, y \in R^d$, $f(y) \geq f(x) + \nabla f(x)^T (y - x)$

上述引理可用于界定遗憾的上界, 我们主要定理的证明通过用 Adam 更新规则替换超平面来构造。以下两个引理用于支持我们的主要定理。我们还使用一些定义来简化符号, 其中 $g_t \triangleq \nabla f_t(\theta_t)$ 和 $g_{t,i}$ 作为第 i^{th} 个元素。我们定义 $g_{1:t,i} \in \mathbb{R}^t$ 为一个向量, 它包含直到 t , $g_{1:t,i} = [g_{1,i}, g_{2,i}, \dots, g_{t,i}]$ 的所有迭代中梯度的第 i^{th} 维。

引理 10.3. 设 $g_t = \nabla f_t(\theta_t)$ 与 $g_{1:t}$ 如上定义且有界, $\|g_t\|_2 \leq G, \|g_t\|_\infty \leq G_\infty$ 。则,

$$\sum_{t=1}^T \sqrt{\frac{g_{t,i}^2}{t}} \leq 2G_\infty \|g_{1:T,i}\|_2$$

证明。我们将通过对 T 进行归纳来证明该不等式。

对于 $T = 1$ 的基本情况, 我们有 $\sqrt{g_{1,i}^2} \leq 2G_\infty \|g_{1,i}\|_2$ 。

对于归纳步骤,

$$\begin{aligned} \sum_{t=1}^T \sqrt{\frac{g_{t,i}^2}{t}} &= \sum_{t=1}^{T-1} \sqrt{\frac{g_{t,i}^2}{t}} + \sqrt{\frac{g_{T,i}^2}{T}} \\ &\leq 2G_\infty \|g_{1:T-1,i}\|_2 + \sqrt{\frac{g_{T,i}^2}{T}} \\ &= 2G_\infty \sqrt{\|g_{1:T,i}\|_2^2 - g_{T,i}^2} + \sqrt{\frac{g_{T,i}^2}{T}} \end{aligned}$$

From, $\|g_{1:T,i}\|_2^2 - g_{T,i}^2 + \frac{g_{T,i}^4}{4\|g_{1:T,i}\|_2^2} \geq \|g_{1:T,i}\|_2^2 - g_{T,i}^2$, we can take square root of both side and have,

$$\begin{aligned} \sqrt{\|g_{1:T,i}\|_2^2 - g_{T,i}^2} &\leq \|g_{1:T,i}\|_2 - \frac{g_{T,i}^2}{2\|g_{1:T,i}\|_2} \\ &\leq \|g_{1:T,i}\|_2 - \frac{g_{T,i}^2}{2\sqrt{TG_\infty^2}} \end{aligned}$$

重排不等式并代入

$$\sqrt{\|g_{1:T,i}\|_2^2 - g_{T,i}^2} \text{ 术语,}$$

$$G_\infty \sqrt{\|g_{1:T,i}\|_2^2 - g_{T,i}^2} + \sqrt{\frac{g_{T,i}^2}{T}} \leq 2G_\infty \|g_{1:T,i}\|_2$$

□

引理 10.4。设 $\gamma \triangleq \beta_1^2$ 。对于满足 $\beta_1, \beta_2 \in [0, 1)$ 的且有界的 $\{g_t\}$ ，以下不等式成立

$$\|g_t\|_\infty \leq G_\infty \quad \frac{\beta_1}{\sqrt{\beta_2}} < 1 \quad g_t, \|g_t\|_2 \leq G,$$

$$\sum_{t=1}^T \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} \leq \frac{2}{1-\gamma} \frac{1}{\sqrt{1-\beta_2}} \|g_{1:T,i}\|_2$$

证明。在假设条件下，。我们可 $\frac{\sqrt{1-\beta_2^t}}{(1-\beta_1^t)^2} \leq \frac{1}{(1-\beta_1)^2}$ 以利用算法 1 中的更新规则展开求和中的最后一项，

$$\begin{aligned} \sum_{t=1}^T \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} &= \sum_{t=1}^{T-1} \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} + \frac{\sqrt{1-\beta_2^T}}{(1-\beta_1^T)^2} \frac{(\sum_{k=1}^T (1-\beta_1)\beta_1^{T-k} g_{k,i})^2}{\sqrt{T \sum_{j=1}^T (1-\beta_2)\beta_2^{T-j} g_{j,i}^2}} \\ &\leq \sum_{t=1}^{T-1} \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} + \frac{\sqrt{1-\beta_2^T}}{(1-\beta_1^T)^2} \sum_{k=1}^T \frac{T((1-\beta_1)\beta_1^{T-k} g_{k,i})^2}{\sqrt{T \sum_{j=1}^T (1-\beta_2)\beta_2^{T-j} g_{j,i}^2}} \\ &\leq \sum_{t=1}^{T-1} \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} + \frac{\sqrt{1-\beta_2^T}}{(1-\beta_1^T)^2} \sum_{k=1}^T \frac{T((1-\beta_1)\beta_1^{T-k} g_{k,i})^2}{\sqrt{T(1-\beta_2)\beta_2^{T-k} g_{k,i}^2}} \\ &\leq \sum_{t=1}^{T-1} \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} + \frac{\sqrt{1-\beta_2^T}}{(1-\beta_1^T)^2} \frac{(1-\beta_1)^2}{\sqrt{T(1-\beta_2)}} \sum_{k=1}^T T \left(\frac{\beta_1^2}{\sqrt{\beta_2}} \right)^{T-k} \|g_{k,i}\|_2 \\ &\leq \sum_{t=1}^{T-1} \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} + \frac{T}{\sqrt{T(1-\beta_2)}} \sum_{k=1}^T \gamma^{T-k} \|g_{k,i}\|_2 \end{aligned}$$

类似地，我们可以对求和中其余各项进行上界估计。

$$\begin{aligned} \sum_{t=1}^T \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} &\leq \sum_{t=1}^T \frac{\|g_{t,i}\|_2}{\sqrt{t(1-\beta_2)}} \sum_{j=0}^{T-t} t\gamma^j \\ &\leq \sum_{t=1}^T \frac{\|g_{t,i}\|_2}{\sqrt{t(1-\beta_2)}} \sum_{j=0}^T t\gamma^j \end{aligned}$$

对于 $\gamma < 1$ ，利用算术-几何级数的上界，

$$t\gamma^t < \frac{1}{(1-\gamma)^2}:$$

$$\sum_{t=1}^T \frac{\|g_{t,i}\|_2}{\sqrt{t(1-\beta_2)}} \sum_{j=0}^T t\gamma^j \leq \frac{1}{(1-\gamma)^2 \sqrt{1-\beta_2}} \sum_{t=1}^T \frac{\|g_{t,i}\|_2}{\sqrt{t}}$$

应用引理 10.3,

$$\sum_{t=1}^T \frac{\hat{m}_{t,i}^2}{\sqrt{t\hat{v}_{t,i}}} \leq \frac{2G_\infty}{(1-\gamma)^2 \sqrt{1-\beta_2}} \|g_{1:T,i}\|_2$$

□

为简化记号，本文定义 $\gamma \triangleq \beta_1^2$ 。直观上，当学习率 α_t 以 $t^{-\frac{1}{2}}$ 的速率衰减，且一阶矩滑动平均系数 $\beta_{1,t}$ 随 λ 指数衰减（通常 λ 接近 1，例如 $1 - 10^{-8}$ 。）时，下述定理成立。

定理 10.5。 假设函数 f_t 具有有界梯度，即对所有 $\theta \in R^d$ 有 $\|\nabla f_t(\theta)\|_2 \leq G, \|\nabla f_t(\theta)\|_\infty \leq G_\infty$ ，且由 Adam 生成的任意 θ_t 之间的距离有界， $\|\theta_n - \theta_m\|_2 \leq D$,