



图 2: 本文所考虑的有向图模型。

本文介绍了扩散概率模型的研究进展 [53]。扩散概率模型（为简洁起见，我们称之为“扩散模型”）是一种参数化的马尔可夫链，通过变分推断训练，在有限时间后生成与数据匹配的样本。该链的转移过程被学习用于逆转扩散过程，而扩散过程是一个马尔可夫链，它沿采样的相反方向逐步向数据添加噪声，直至信号被破坏。当扩散由少量高斯噪声组成时，只需将采样链的转移也设为条件高斯分布，即可实现一种特别简单的神经网络参数化。

扩散模型易于定义且训练高效，但据我们所知，此前尚无证据表明它们能够生成高质量样本。我们证明扩散模型实际上能够生成高质量样本，有时甚至优于其他类型生成模型已发表的结果（第 4 节）。此外，我们证明扩散模型的某种参数化方式揭示了训练期间多噪声水平下的去噪分数匹配与采样期间退火朗之万动力学之间的等价性（第 3.2 节）[55, 61]。我们使用该参数化获得了最佳的样本质量结果（第 4.2 节），因此我们认为这一等价性是本文的主要贡献之一。

尽管样本质量优异，与其他基于似然的模型相比，我们的模型在对数似然方面并不具备竞争力（然而，我们的模型对数似然优于已报道的能量基模型和分数匹配在大规模估计退火重要性采样下产生的结果 [11, 55]）。我们发现，模型的无损编码长度大部分用于描述难以察觉的图像细节（第 4.3 节）。我们以有损压缩的语言对这一现象进行了更精细的分析，并证明扩散模型的采样过程是一种渐进式解码，类似于沿比特顺序的自回归解码，极大地扩展了自回归模型通常所能实现的范围。

2 背景

扩散模型 [53] 是形式为 $p_\theta(\mathbf{x}_0) := \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}$ 的潜变量模型，其中 $\mathbf{x}_1, \dots, \mathbf{x}_T$ 是与数据 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 维度相同的隐变量。联合分布 $p_\theta(\mathbf{x}_{0:T})$ 称为逆过程，它被定义为一个马尔可夫链，其学习到的高斯转移从 $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$ 开始。

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t), \quad p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)) \quad (1)$$

扩散模型与其他潜变量模型的区别在于，近似后验 $q(\mathbf{x}_{1:T}|\mathbf{x}_0)$ （称为前向过程或扩散过程）被固定为一个马尔可夫链，该链根据方差调度 $\beta_1, \dots, \beta_T$ 逐步向数据添加高斯噪声。

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1}), \quad q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \quad (2)$$

训练通过优化负对数似然的通常变分下界来进行：

$$\mathbb{E}[-\log p_\theta(\mathbf{x}_0)] \leq \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] =: L \quad (3)$$

前向过程的方差 β_t 可以通过重参数化 [33] 学习，或作为超参数保持不变，而逆过程的表达能力部分由 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 中高斯条件分布的选择来保证，因为当 β_t 很小时，两个过程具有相同的函数形式 [53]。前向过程的一个显著性质是，它允许在任意时间步 t 以闭式形式采样 $\mathbf{x}_t$ ：使用记号 $\alpha_t := 1 - \beta_t$ 和 $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$ ，我们有

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad (4)$$