

高速公路网络在深度极大增加（例如超过 100 层）时尚未展现出准确率提升。

3. 深度残差学习

3.1. 残差学习

让我们将 $\mathcal{H}(\mathbf{x})$ 视为一个由几层堆叠层（不一定是整个网络）拟合的底层映射，其中 $\mathbf{x}$ 表示这些层中第一层的输入。如果假设多个非线性层可以渐近地逼近复杂函数 $\mathcal{H}$ ，那么等价地假设它们可以渐近地逼近残差函数 *i.e.*, $\mathcal{H}(\mathbf{x}) - \mathbf{x}$ （假设输入和输出具有相同的维度）。因此，与其期望堆叠层逼近 $\mathcal{H}(\mathbf{x})$ ，我们明确让这些层逼近残差函数 $\mathcal{F}(\mathbf{x}) := \mathcal{H}(\mathbf{x}) - \mathbf{x}$ 。原始函数因此变为 $\mathcal{F}(\mathbf{x}) + \mathbf{x}$ 。尽管两种形式都应该能够渐近地逼近期望的函数（如假设的那样），但学习的难易程度可能不同。这种重新表述的动机来自关于退化问题的反直觉现象（图 1，左）。正如我们在引言中讨论的，如果添加的层可以被构造为恒等映射，那么更深的模型应该具有不大于其较浅对应物的训练误差。退化问题表明求解器可能难以通过多个非线性层逼近恒等映射。通过残差学习的重新表述，如果恒等映射是最优的，求解器可以简单地将多个非线性层的权重驱动到零以接近恒等映射。在实际情况下，恒等映射不太可能是最优的，但我们的重新表述可能有助于对问题进行预处理。如果最优函数比零映射更接近恒等映射，那么求解器应该更容易参照恒等映射找到扰动，而不是将函数作为新函数来学习。我们通过实验（图 7）表明，学习到的残差函数通常具有较小的响应，这表明恒等映射提供了合理的预处理。

3.2. 通过捷径实现恒等映射

我们对每几个堆叠层采用残差学习。一个构建块如图 2 所示。形式上，在本文中我们考虑一个定义为以下形式的构建块：

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}. \quad (1)$$

这里 $\mathbf{x}$ 和 $\mathbf{y}$ 分别是所考虑层的输入和输出向量。函数 $\mathcal{F}(\mathbf{x}, \{W_i\})$ 表示要学习的残差映射。对于图 2 中具有两层的示例， $\mathcal{F} = W_2\sigma(W_1\mathbf{x})$ 其中 σ 表示 ReLU 。然而，这个假设仍然是一个开放问题。参见 [28]。

修正线性单元 (ReLU) [29] 和偏差被省略以简化符号。操作 $\mathcal{F} + \mathbf{x}$ 通过捷径连接和逐元素加法执行。我们在加法后采用第二个非线性函数 (*i.e.*, $\sigma(\mathbf{y})$)，见图 2)。公式 (1) 中的捷径连接既不引入额外参数也不增加计算复杂度。这不仅在实践中具有吸引力，而且在我们比较普通网络和残差网络时也很重要。我们可以公平地比较同时具有相同参数数量、深度、宽度和计算成本（除了可忽略的逐元素加法）的普通/残差网络。在公式 (1) 中， $\mathbf{x}$ 和 $\mathcal{F}$ 的维度必须相等。如果不是这种情况（例如，当改变输入/输出通道时），我们可以通过捷径连接执行线性投影 W_s 来匹配维度：

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + W_s\mathbf{x}. \quad (2)$$

我们也可以在公式 (1) 中使用方阵 W_s 。但我们将通过实验表明，恒等映射足以解决退化问题且经济，因此 W_s 仅在匹配维度时使用。残差函数 $\mathcal{F}$ 的形式是灵活的。本文中的实验涉及具有两层或三层的函数 $\mathcal{F}$ （图 5），而更多层也是可能的。但如果 $\mathcal{F}$ 只有单层，公式 (1) 类似于线性层： $\mathbf{y} = W_1\mathbf{x} + \mathbf{x}$ ，我们没有观察到其优势。

我们还注意到，尽管上述符号为了简单起见是关于全连接层的，但它们适用于卷积层。函数 $\mathcal{F}(\mathbf{x}, \{W_i\})$ 可以表示多个卷积层。逐元素加法在两个特征图上逐通道执行。

3.3. 网络架构

我们测试了各种普通/残差网络，并观察到一致的现象。为了提供讨论实例，我们描述了两个用于 ImageNet 的模型如下。

普通网络。我们的朴素基线（图 3，中）主要受 VGG 网络 [41]（图 3，左）的设计理念启发。卷积层大多使用 3×3 滤波器，并遵循两条简单的设计规则：(i) 对于相同的输出特征图尺寸，各层具有相同数量的滤波器；(ii) 如果特征图尺寸减半，则滤波器数量加倍，以保持每层的时间复杂度。我们直接通过步长为 2 的卷积层进行下采样。网络以一个全局平均池化层和一个带有 Softmax 函数的 1000 路全连接层结束。图 3（中）的加权层总数为 34。值得注意的是，我们的模型比 VGG 网络 [41]（图 3，左）具有更少的滤波器和更低的复杂度。我们的 34 层基线的 FLOPs（乘法运算）为 36 亿，仅为 VGG-19（196 亿 FLOPs）的 18%。