

中间变换器层与全局 [CLS] 标记。DPT 融合颈部将这些多尺度特征重组并融合为共享几何特征图 $\mathbf{G} \in \mathbb{R}^{C \times H \times W}$ 。我们将 ViT 骨干与融合颈部合称为几何编码器，因为它生成所有下游组件使用的域不变表示。从 $\mathbf{G}$ 出发，两个轻量预测头产生互补输出：深度头预测逆深度图 $\hat{\mathbf{d}} \in \mathbb{R}^{1 \times H \times W}$ ，法线头预测单位表面法线图 $\hat{\mathbf{n}} \in \mathbb{R}^{3 \times H \times W}$ 。这些预测头仅在训练期间用于提供几何监督；部署时即被丢弃。从共享表示中同时预测两种模态，迫使编码器学习比单独任一任务更丰富的几何信息，因为深度捕捉到表面的距离，而法线捕捉其局部朝向。对于下游策略，几何编码器导出两类特征：通过将 $\mathbf{G}$ 投影经过学习的 1×1 卷积获得的密集空间特征图，以及作为全局场景描述符的 [CLS] 标记。在策略学习期间，编码器被冻结以保留学到的几何归纳偏置。

模型训练。

几何编码器和预测头在 Isaac Lab [21] 中渲染的合成 RGB-深度-法线三元组上联合训练，该平台提供像素级完美的真实标注。我们应用颜色抖动和几何扰动，并辅以相应的法线旋转补偿，以提高对视觉变化的鲁棒性。总损失结合了深度监督、法线监督和跨任务一致性项：

$$\mathcal{L}_{\text{enc}} = \underbrace{\lambda_{\text{ssi}} \mathcal{L}_{\text{ssi}} + \lambda_{\text{gm}} \mathcal{L}_{\text{gm}}}_{\text{depth}} + \underbrace{\lambda_{\text{cos}} \mathcal{L}_{\text{cos}} + \lambda_{\text{geo}} \mathcal{L}_{\text{geo}}}_{\text{normal}} + \underbrace{\lambda_{\text{dn}} \mathcal{L}_{\text{dn}}}_{\text{consistency}}. \quad (1)$$

深度项包含一个尺度与平移不变的损失 $\mathcal{L}_{\text{ssi}}$ [31] 和一个保留深度不连续性的梯度匹配损失 $\mathcal{L}_{\text{gm}}$ 。法线项包含一个衡量与真值角度偏差的余弦损失 $\mathcal{L}_{\text{cos}}$ 和一个边缘感知平滑损失 $\mathcal{L}_{\text{geo}}$ ，该损失在尊重深度边界的同时促进空间一致性。核心项是深度-法线一致性损失 $\mathcal{L}_{\text{dn}}$ 。给定深度图和相机内参 $\mathbf{K}$ ，可通过将像素反投影到三维并计算有限差分的叉积来解析推导表面法线。我们利用这种几何耦合作为自洽性约束：

$$\mathcal{L}_{\text{dn}} = \frac{1}{|\mathcal{M}|} \sum_{p \in \mathcal{M}} \left(1 - \hat{\mathbf{n}}_p^\top \mathbf{n}_p^{(\text{d})} \right), \quad (2)$$

其中 $\mathbf{n}_p^{(\text{d})}$ 是从像素 p 处的预测深度推导出的法线， $\mathcal{M}$ 是具有可靠深度的有效像素集合。该损失无需额外标签，却迫使两个头部收敛到一致的三维解释，从而产生更具结构性和可迁移的特征。完整细节见附录 B.2。