

具体而言，我们定义了一个归一化参数空间 $\alpha \in [-1,1]^D$ ，其中原点对应标称配置，极值对应最严苛的极限。该分布由 M 个虚拟粒子 $\{\mathbf{v}^{(m)}\}_{m=1}^M$ ， $M \geq 1$ ，表示，每个自适应领域随机化周期内通过三个阶段更新。首先，轻量级神经判别器 $D_\phi(\alpha)$ 基于近期 rollout 结果进行训练，以估计整个参数空间中的失败概率，为难度景观提供可微代理。其次，粒子通过 SVGD [18] 进行传输：

$$\phi^*(\mathbf{v}^{(m)}) = \frac{1}{M} \sum_{j=1}^M \left[\underbrace{k(\mathbf{v}^{(j)}, \mathbf{v}^{(m)}) \nabla_{\mathbf{v}^{(j)}} \log D_\phi(\mathbf{v}^{(j)})}_{\text{driving force}} + \underbrace{\nabla_{\mathbf{v}^{(j)}} k(\mathbf{v}^{(j)}, \mathbf{v}^{(m)})}_{\text{repulsive force}} \right], \quad (3)$$

其中 $k(\cdot, \cdot)$ 是带宽由中位数启发式设定的径向基函数核。驱动力将粒子推向高难度区域，而排斥力防止模式崩塌。第三，粒子云通过鲁棒百分位数统计投影到轴对齐边界，并传递给模拟器。为防止灾难性难度升级，更新由当前成功率控制：仅当性能足够高时，完整的 VP-SVGD 周期才执行；当成功率降至低阈值以下时，粒子向原点收缩，直至策略恢复；介于两者之间时，分布保持固定。该课程确保随机化边界跟踪策略不断演进的能力，如第 4.4 节所验证。

3.3 扩散策略蒸馏

特权专家无法直接部署，因为它需要真实世界中不可用的真实状态。我们将其行为蒸馏为扩散策略，该策略以冻结的几何特征和机器人关节位置作为输入，并通过迭代去噪生成动作块。扩散公式非常适合此场景：领域随机化会引发多模态动作分布，而单模态策略会因平均化而崩塌；预测动作块可生成时间连贯的轨迹，从而抑制接触密集型操作中常见的振荡。

数据收集。

我们在完整的日常活动机器人（ADR）参数分布上部署训练好的专家模型，以收集数据集 $\{\mathbf{I}_t^c, \mathbf{q}_t, \mathbf{a}_{t:t+H-1}\}$ ，其中 $\mathbf{I}_t^c$ 和 $\mathbf{I}_t^s$ 分别为头部与胸部相机的 RGB 图像， $\mathbf{q}_t$ 为机器人关节位置向量， $\mathbf{a}_{t:t+H-1}$ 为从时刻 t 开始的 H 个连续专家动作片段。

扩散策略以冻结的几何编码器（§ 3.1）作为观测主干，并以一维扩散变换器（DiT）[25] 作为去噪主干。我们利用条件去噪扩散框架 [5,12] 对动作片段 $\mathbf{a}_0 \in \mathbb{R}^{H \times d_a}$ 上的条件分布进行建模。每幅相机图像由该编码器独立处理，所得特征在通过两条条件路径进入 DiT 之前进行拼接。编码器输出的密集空间特征图被展平为令牌序列，而机器人关节位置则通过轻量级多层感知机（MLP）进行编码。