




图 5: RoboTwin 2.0 基准性能。在 8 项操作任务中，比较 π_0 基线、单头专家模型和我们的完整模型的成功率。虽然特定头在对应任务上表现出色（例如，深度头在几何密集的“敲击锤块”任务中表现优异），但完整模型（紫色）整合了这些能力，达到了最佳的整体平均性能（90.63%）。

两个碗并将其放置在架子上，以及（3）清洁桌面：用扫帚/簸箕清扫垃圾，倒入托盘中。在 PSI-Bot RealMan 平台上，我们设计了三个化学实验室操作任务：

（4）将烧杯放入加热套：抓取烧杯并将其插入加热套中，（5）堆叠烧杯：将小烧杯嵌套在大烧杯内，以及（6）加热烧杯：在铁架台上放置石棉网，然后将烧杯放在石棉网上。这些实验室任务聚焦于透明、刚性物体和紧密几何约束所带来的操作挑战。它们并不评估完整的安全关键化学流程；特别是，加热烧杯仅要求将烧杯放置在加热装置上，而非控制加热过程本身。

Detailed success criteria are provided in Appendix L2.

Evaluation protocol

对于每项任务和每个模型，我们进行 20 次试验。若整个任务完成，则试验成功。

Generalization evaluation

我们在两个平台上评估三种泛化设置：域内泛化、场景泛化和光照泛化。其中，域内泛化关注训练分布内的物体位置变化，同时保持任务语义和场景布局。场景泛化在工作空间中引入干扰物体，测试对杂乱和语义干扰的鲁棒性。光照泛化改变光照强度和色温，评估对感知变化的敏感性。结果总结于表 II，详细设置定义见附录 M。

五、分析

在本节中，我们旨在回答以下问题：

- 1) 视觉-语言-动作模型（VLA）在动作解码过程中是否未充分利用视觉-语言表征，显式因子引导能否弥补这一差距？（第 V-B 节）
- 2) 我们提出的 GuidedVLA 是否在分布内和分布外评估下均提升了基线性能？（第 V-A 节）
- 3) 哪些因子（物体、技能、几何）对哪些任务类型最为关键？（第 V-A 节）

- 4) 注意力头专业化是否确实导致了解耦特征的学习？（第 V-C 节）
- 5) 不同的引导架构选择如何影响性能？（第 V-E 节）

A. Task-suite Analysis and Cross-benchmark Generalization

本文分析了各因素对不同任务套件的贡献，并利用仿真和真实世界评估的代表性结果，解释为何每个指定头有所帮助。

Object Head: Visual Generalization

涉及杂乱或干扰物的任务需要精确理解对象实例身份。在强调对象级区分的 LIBERO-Plus Object 套件上，对象头产生了最强的单头结果（82.5%，比 π_0 提高 8.4%，表 I；完整结果见附录 B）。这与直觉一致，即显式的以对象为中心的表示减轻了定位失败，使策略能够过滤掉混淆基线的无关视觉线索。

技能头：时序一致性。

长周期操作需要保持“阶段感知”，以便在子技能之间正确过渡。在 LIBERO-Plus 上，技能头在目标套件上取得了最佳单头结果（68.9%），并在长周期套件上保持在 π_0 以上（62.7% 对比 60.1%，表 I）。类似地，对于涉及抓取、稳定和提升严格序列的提锅任务（RoboTwin 2.0），该头实现了最佳单头成功率（96%，图 5；完整结果见附录 B）。这些结果验证了显式技能识别提供了所需的时间框架，以防止阶段转换中的过早终止或模式崩塌。

- 1) 视觉-语言-动作模型（VLA）在动作解码过程中是否未充分利用视觉-语言表征，显式因子引导能否弥补这一差距？（第 V-B 节）

依赖于精确三维定位的任务，如按压或插入，需要准确的深度估计，而仅靠二维主干通常无法提供。在 RoboTwin 2.0 上，按铃任务需要精确的 Z 轴控制以无碰撞地触发机制；深度头将性能从 35% 大幅提升至 63%（图 5）。我们在敲锤任务中观察到类似趋势。